Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Grasia Okta Adelia
NIM 124400059
Teknik Telekomunikasi, ITERA
grasia.124400059@student.itera.ac.id

Egista Marga Kola
NIM 124400003
Teknik Telekomunikasi, ITERA
egista.124400003@student.itera.ac.id

Muhammad Allam Dzaky
NIM 124400013
Teknik Telekomunikasi, ITERA
muhammad.1244000013@student.itera.ac.id

***Ringkasan*—trafik internet per jam merupakan tantangan dalam pengelolaan jaringan telekomunikasi karena pola penggunaan berubah berdasarkan waktu dan lokasi. Penelitian ini menggunakan dataset Telecom Italia pada kotak geografis Duomo dan lokasi kelompok, yaitu Stadio San Siro, untuk mengevaluasi empat arsitektur, yaitu Artificial Neural Network (ANN), Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU). Eksperimen ablasi menguji pengaruh panjang jendela input (window size), jumlah unit tersembunyi (hidden size), jumlah lapisan (layers), laju pembelajaran (learning rate), pemilihan fitur, ukuran batch, dan fungsi loss. Setiap konfigurasi dievaluasi menggunakan tiga seed. Pada Duomo, konfigurasi terbaik menurunkan test MAE ANN dari 309,9 menjadi 273,3, GRU dari 237,2 menjadi 233,8, dan LSTM dari 273,6 menjadi 247,3, sedangkan RNN meningkat dari 229,6 menjadi 242,9. Pada Stadio San Siro, LSTM menghasilkan test MAE 10,9 ± 0,1, turun 20,4 persen dari acuan 13,7 ± 0,8, sementara GRU mencapai 11,4 ± 0,3, turun 10,9 persen dari acuan 12,8 ± 0,6. Hasil ini menunjukkan bahwa efektivitas optimasi hiperparameter bergantung pada arsitektur dan lokasi, sehingga evaluasi lintas lokasi diperlukan untuk menilai kemampuan generalisasi model.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

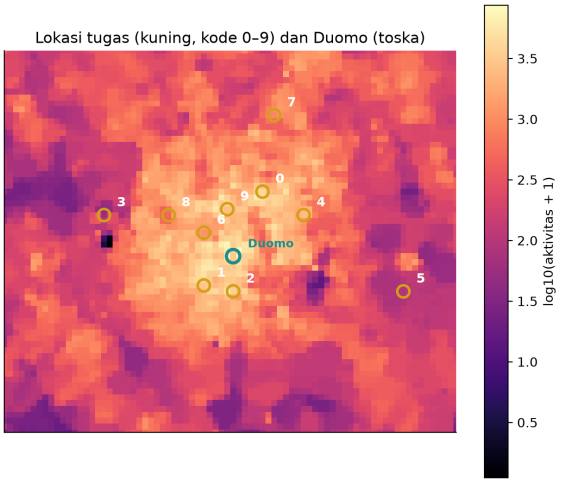
Prediksi trafik internet diperlukan untuk mendukung perencanaan kapasitas dan alokasi sumber daya jaringan berdasarkan kebutuhan pengguna yang berubah terhadap waktu [1]. Penelitian ini membandingkan ANN dengan model sekuensial RNN, LSTM [2], dan GRU [3] untuk mengevaluasi kinerja prediksi berdasarkan data historis. Studi ablasi dilakukan untuk menganalisis pengaruh hiperparameter dan pemilihan fitur terhadap kinerja model. Kontribusi penelitian ini meliputi:

- Membandingkan kinerja ANN, RNN, LSTM, dan GRU dalam prediksi trafik per jam.
- Menganalisis pengaruh hiperparameter dan fitur melalui studi ablasi.
- Mengevaluasi konfigurasi terbaik terhadap model acuan serta menguji kinerjanya pada lokasi kelompok.

II. Data dan Metode

A. Dataset

Penelitian ini menggunakan dataset Telecom Italia Big Data Challenge yang merekam aktivitas jaringan seluler di Kota Milan, Italia. Dataset tersebut mencakup aktivitas internet, panggilan, dan SMS yang dikelompokkan berdasarkan lokasi geografis dan waktu [4]. Eksperimen dilakukan pada kotak geografis Duomo dengan ID 5060 sebagai lokasi acuan dan kawasan Stadio San Siro sebagai lokasi kelompok untuk mengevaluasi kinerja model pada lokasi yang berbeda. Data trafik diolah dalam resolusi per jam dan digunakan untuk membandingkan kinerja ANN, RNN, LSTM, dan GRU dalam memprediksi trafik internet berdasarkan data historis.



Gambar 1. Peta grid geografis dan lokasi eksperimen di Kota Milan.

Gambar 1 menunjukkan lokasi geografis yang digunakan dalam eksperimen pada wilayah Milan.

B. Pembagian Data dan Praproses

Data dibagi secara kronologis menjadi data latih (*training*), validasi (*validation*), pengujian (*test*), dan periode Natal. Pembagian berdasarkan waktu dilakukan untuk mempertahankan urutan temporal dan menghindari kebocoran informasi dari masa mendatang ke dalam data latih.

Standardisasi dilakukan menggunakan statistik dari data sebelum periode validasi. Parameter standardisasi yang sama kemudian diterapkan pada data validasi dan pengujian agar informasi dari data evaluasi tidak memengaruhi proses pelatihan.

Selanjutnya, data disusun menggunakan metode *sliding window* dengan panjang jendela 24 jam untuk memprediksi trafik

Tabel I
KONFIGURASI ACUAN

Hiperparameter	Nilai Acuan
Jendela masukan	24 jam
Horizon prediksi	1 jam
Hidden size	ANN: 32; RNN: 68; LSTM: 33; GRU: 38
Jumlah lapisan	ANN: 2; RNN/LSTM/GRU: 1
Fitur masukan	7 fitur trafik dan waktu
Optimizer	Adam
Laju pembelajaran	10^{-3}
Batch size	64
Early stopping	Patience 30; maks. 300 epoch

internet pada satu jam berikutnya. Data ini digunakan sebagai masukan bagi model ANN, RNN, LSTM, dan GRU.

C. Model dan Konfigurasi Acuan

Konfigurasi awal yang digunakan dalam eksperimen dirangkum pada Tabel I. Konfigurasi ini digunakan untuk membandingkan kinerja ANN, RNN, LSTM, dan GRU sebelum dilakukan eksperimen ablasi.

D. Protokol Ablasi dan Evaluasi

Eksperimen ablasi dilakukan dengan mengubah satu faktor pada setiap percobaan, sedangkan parameter lainnya dipertahankan pada nilai acuan. Lima faktor yang diuji meliputi panjang jendela $W \in \{6, 12, 24, 48, 168\}$, ukuran *hidden* $\in \{16, 32, 64, 128\}$, jumlah lapisan $\in \{1, 2, 3\}$, laju pembelajaran $\in \{10^{-4}, 10^{-3}, 10^{-2}\}$, dan kelompok fitur masukan $\in \{\texttt{net}, \texttt{net+call+sms}, \texttt{net+waktu}, \texttt{semua}\}$.

Dua faktor tambahan yang dipilih adalah ukuran *batch* (16, 64, dan 256) serta fungsi *loss* (MSE, MAE, dan Huber). Hipotesis awal untuk ukuran *batch* adalah bahwa ukuran yang lebih kecil dapat menghasilkan pembaruan parameter yang lebih sering, tetapi juga lebih berfluktuasi. Untuk fungsi *loss*, MAE atau Huber diperkirakan dapat memberikan hasil yang kompetitif terhadap metrik MAE, terutama jika terdapat nilai trafik ekstrem.

Setiap konfigurasi diuji menggunakan tiga *seed*, yaitu 0, 1, dan 2. Kinerja dievaluasi menggunakan MAE, RMSE, dan MAPE pada skala trafik asli. Hasil dilaporkan sebagai rata-rata dan simpangan baku dari tiga *seed*. Pemilihan konfigurasi terbaik untuk setiap model didasarkan pada rata-rata MAE validasi. Data pengujian dan periode Natal digunakan untuk evaluasi akhir, bukan untuk memilih konfigurasi.

Pelatihan dilakukan menggunakan [CPU/GPU, sesuaikan dengan perangkat yang digunakan]. Total waktu pelatihan dicatat untuk setiap proses eksperimen dan dirangkum dari hasil pencatatan pada notebook.

E. Baseline Naif dan Acuan

Baseline naif digunakan sebagai pembanding dengan memprediksi trafik pada satu jam berikutnya menggunakan nilai trafik pada jam sebelumnya. Selanjutnya, kinerja baseline dibandingkan dengan model ANN, RNN, LSTM, dan GRU menggunakan konfigurasi acuan. Evaluasi dilakukan pada

Tabel II
MAE KONFIGURASI ACUAN PADA DUOMO

Model	Test MAE	Natal MAE
ANN	309.9 ± 5.9	680.1 ± 52.0
RNN	229.6 ± 5.1	421.2 ± 2.4
LSTM	273.6 ± 25.4	586.0 ± 56.8
GRU	237.2 ± 9.3	468.2 ± 21.8

Tabel III
PENGARUH PANJANG JENDELA TERHADAP TEST MAE

W (jam)	ANN	RNN	LSTM	GRU
6	268.9 ± 17.7	228.6 ± 5.4	276.3 ± 14.7	249.8 ± 1.4
12	307.8 ± 13.1	233.2 ± 11.2	302.7 ± 17.4	246.1 ± 13.5
24	309.9 ± 5.9	229.6 ± 5.1	273.6 ± 25.4	237.2 ± 9.3
48	333.3 ± 20.5	224.5 ± 11.7	304.4 ± 27.1	237.1 ± 10.6
168	402.0 ± 12.5	233.5 ± 4.8	292.8 ± 20.0	237.2 ± 10.6

minggu pengujian dan periode Natal menggunakan metrik MAE, RMSE, dan MAPE pada skala asli.

1) A1. Pengaruh Panjang Jendela: Ablasi A1 menguji panjang jendela masukan $W \in \{6, 12, 24, 48, 168\}$ jam. Hasil pengujian ditampilkan pada Tabel III. Panjang jendela yang lebih besar tidak selalu menghasilkan MAE yang lebih rendah. Pada ANN, MAE meningkat ketika jendela diperpanjang dari 6 menjadi 168 jam. Sebaliknya, RNN memperoleh MAE terendah pada $W = 48$ jam, yaitu 224.5 ± 11.7. Hasil ini menunjukkan bahwa pengaruh panjang jendela bergantung pada arsitektur model.

F. Ablasi Pilihan

1) Pengaruh Ukuran Batch: Hipotesis awal pada eksperimen ini adalah ukuran batch yang lebih kecil dapat meningkatkan kinerja model karena pembaruan parameter dilakukan lebih sering, meskipun variasi pembaruan dapat menjadi lebih besar. Pengaruh ukuran batch diuji dengan membandingkan batch 16, 64, dan 256, sementara hiperparameter lainnya dipertahankan.

Hasil menunjukkan bahwa pengaruh ukuran batch berbeda pada setiap arsitektur. Pada ANN, batch 256 menghasilkan test MAE terendah sebesar 254.5 ± 13.2, dibandingkan 302.1 ± 12.8 pada batch 16 dan 309.9 ± 5.9 pada batch 64. Sebaliknya, LSTM memperoleh MAE terendah pada batch 16, yaitu 248.9 ± 35.2, sedangkan GRU juga memperoleh MAE terendah pada batch 16, yaitu 232.2 ± 10.3. Pada RNN, rata-rata MAE batch 16 dan batch 256 sama-sama sebesar 228.3, tetapi batch 16 memiliki simpangan baku yang lebih rendah.

Hasil tersebut menunjukkan bahwa batch yang lebih kecil tidak selalu menghasilkan kinerja terbaik pada semua model. Hipotesis awal hanya didukung pada beberapa arsitektur, sehingga pemilihan ukuran batch perlu mempertimbangkan karakteristik masing-masing model.

2) Pengaruh Fungsi Loss: Hipotesis awal pada eksperimen ini adalah fungsi loss MAE dapat menghasilkan prediksi dengan MAE lebih rendah karena fungsi optimasi yang digunakan sesuai dengan metrik evaluasi utama. Eksperimen

Tabel IV
PENGARUH UKURAN BATCH TERHADAP TEST MAE

Batch	ANN	RNN	LSTM	GRU
16	302.1 ± 12.8	228.3 ± 6.7	248.9 ± 35.2	232.2 ± 10.3
64	309.9 ± 5.9	229.6 ± 5.1	273.6 ± 25.4	237.2 ± 9.3
256	254.5 ± 13.2	228.3 ± 17.4	269.6 ± 10.8	233.8 ± 15.6

Tabel V
PENGARUH FUNGSI LOSS TERHADAP TEST MAE

Loss	ANN	RNN	LSTM	GRU
MSE	309.9 ± 5.9	229.6 ± 5.1	273.6 ± 25.4	237.2 ± 9.3
MAE	297.2 ± 10.9	207.6 ± 2.8	265.9 ± 17.8	229.4 ± 16.5
Huber	315.6 ± 4.6	225.3 ± 3.0	271.6 ± 30.3	236.5 ± 7.7

Tabel VI
PERBANDINGAN KONFIGURASI ACUAN DAN TERBAIK

Model	Konfigurasi	Test MAE	Natal MAE
ANN	Acuan	309.9 ± 5.9	680.1 ± 52.0
ANN	Terbaik	272.9 ± 23.5	607.6 ± 101.4
RNN	Acuan	229.6 ± 5.1	421.2 ± 2.4
RNN	Terbaik	242.2 ± 13.3	421.7 ± 27.9
LSTM	Acuan	273.6 ± 25.4	586.0 ± 56.8
LSTM	Terbaik	246.6 ± 12.0	462.7 ± 5.2
GRU	Acuan	237.2 ± 9.3	468.2 ± 21.8
GRU	Terbaik	228.6 ± 6.6	433.2 ± 25.4

membandingkan fungsi loss MSE, MAE, dan Huber dengan mempertahankan hiperparameter lainnya.

Hasil pengujian menunjukkan bahwa loss MAE menghasilkan test MAE terendah pada keempat arsitektur. Pada RNN, test MAE turun dari 229.6 ± 5.1 dengan loss MSE menjadi 207.6 ± 2.8 dengan loss MAE. Pola serupa terlihat pada ANN, LSTM, dan GRU. ANN memperoleh MAE sebesar 297.2 ± 10.9, LSTM sebesar 265.9 ± 17.8, dan GRU sebesar 229.4 ± 16.5 ketika menggunakan loss MAE.

Dengan demikian, hasil eksperimen mendukung hipotesis awal untuk metrik MAE pada seluruh arsitektur yang diuji. Namun, hasil ini tidak cukup untuk menyimpulkan bahwa loss MAE juga menghasilkan RMSE terbaik karena RMSE tidak ditampilkan pada perbandingan ini.

G. Konfigurasi Terbaik

Konfigurasi terbaik untuk setiap arsitektur ditentukan berdasarkan rata-rata MAE pada data validasi dari tiga seed. Data test dan periode Natal digunakan untuk mengevaluasi konfigurasi terpilih, bukan untuk menentukan konfigurasi terbaik. Hasil konfigurasi terbaik kemudian dibandingkan dengan konfigurasi acuan pada Tabel VI.

Berdasarkan hasil tersebut, konfigurasi terbaik meningkatkan kinerja ANN, LSTM, dan GRU pada minggu test dibandingkan konfigurasi acuan. Penurunan MAE paling besar di antara ketiga model tersebut terlihat pada ANN, dari 309.9 menjadi 272.9. GRU juga mengalami penurunan MAE dari 237.2 menjadi 228.6. Sebaliknya, RNN mengalami kenaikan MAE dari 229.6 menjadi 242.2, sehingga konfigurasi terbaik berdasarkan validasi tidak selalu menghasilkan kinerja test yang lebih baik.

Pada periode Natal, MAE ANN, LSTM, dan GRU juga lebih rendah dibandingkan konfigurasi acuannya. Sementara itu, MAE RNN relatif sama, yaitu 421.2 pada konfigurasi acuan dan 421.7 pada konfigurasi terbaik. Hasil ini menunjukkan bahwa pengaruh perubahan hiperparameter dapat berbeda antara minggu test dan periode Natal.

Tabel VII
HASIL UJI GENERALISASI DI STADIO SAN SIRO

Model	Konfigurasi	Test MAE	Natal MAE
ANN	Acuan	13.6 ± 1.3	13.4 ± 3.0
ANN	Terbaik	15.1 ± 1.3	5.0 ± 0.5
RNN	Acuan	12.7 ± 0.1	9.1 ± 0.7
RNN	Terbaik	12.9 ± 0.4	9.3 ± 0.6
LSTM	Acuan	13.7 ± 0.8	7.0 ± 0.4
LSTM	Terbaik	11.2 ± 0.9	6.2 ± 0.2
GRU	Acuan	12.8 ± 0.6	9.0 ± 0.4
GRU	Terbaik	11.4 ± 0.3	6.3 ± 0.8

H. Uji Generalisasi

Uji generalisasi dilakukan pada Stadio San Siro, yaitu lokasi kelompok dengan kode 3 dan grid 5738. Konfigurasi acuan dan konfigurasi terbaik dilatih serta dievaluasi pada lokasi ini untuk melihat apakah hasil yang diperoleh pada Duomo juga berlaku di lokasi yang berbeda.

Pada minggu test di Stadio San Siro, konfigurasi acuan RNN memperoleh MAE terendah sebesar 12.7 ± 0.1, diikuti GRU sebesar 12.8 ± 0.6. Pada konfigurasi terbaik, LSTM memperoleh MAE terendah sebesar 11.2 ± 0.9, diikuti GRU sebesar 11.4 ± 0.3. Dengan demikian, urutan kinerja model berubah setelah konfigurasi terbaik diterapkan: LSTM menjadi model dengan MAE terendah, sedangkan RNN tidak lagi menjadi model terbaik.

Pada periode Natal, konfigurasi terbaik menghasilkan MAE yang lebih rendah untuk ANN, LSTM, dan GRU dibandingkan konfigurasi acuan. ANN menunjukkan penurunan paling besar, dari 13.4 ± 3.0 menjadi 5.0 ± 0.5. Sebaliknya, MAE RNN sedikit meningkat dari 9.1 ± 0.7 menjadi 9.3 ± 0.6.

Perbedaan hasil antara Duomo dan Stadio San Siro menunjukkan bahwa kinerja model bergantung pada lokasi dan periode evaluasi. Perubahan pola trafik pada lokasi yang berbeda dapat memengaruhi kemampuan model dalam memprediksi trafik. Oleh karena itu, model dengan kinerja terbaik pada satu lokasi belum tentu menjadi model terbaik pada lokasi lain.

III. PEMBAHASAN

Hasil eksperimen menunjukkan bahwa kinerja model tidak hanya ditentukan oleh arsitektur, tetapi juga dipengaruhi oleh pemilihan hiperparameter dan fitur masukan. Tidak ada satu konfigurasi yang selalu memberikan hasil terbaik pada semua arsitektur dan periode evaluasi. Oleh karena itu, hasil ablasi

perlu dilihat sebagai interaksi antara arsitektur model, konfigurasi pelatihan, dan karakteristik data trafik.

A. Pengaruh Hiperparameter terhadap Kinerja Model

Panjang jendela masukan memberikan pengaruh yang berbeda pada setiap arsitektur. Pada ANN, test MAE meningkat dari 268.9 ± 17.7 ketika menggunakan jendela 6 jam menjadi 402.0 ± 12.5 pada jendela 168 jam. Sebaliknya, RNN memperoleh MAE terendah pada jendela 48 jam, yaitu 224.5 ± 11.7. Hasil ini menunjukkan bahwa penambahan informasi historis tidak selalu meningkatkan kemampuan prediksi. Jendela yang terlalu panjang dapat menambah informasi yang kurang relevan, sedangkan panjang jendela yang sesuai dapat membantu model menangkap pola temporal.

Jumlah lapisan juga memengaruhi setiap arsitektur secara berbeda. Pada RNN, test MAE terendah diperoleh dengan dua lapisan, yaitu 228.4 ± 8.2, dibandingkan 229.6 ± 5.1 pada satu lapisan dan 245.5 ± 19.1 pada tiga lapisan. Pada LSTM, test MAE meningkat dari 273.6 ± 25.4 pada satu lapisan menjadi 412.6 ± 54.2 pada tiga lapisan. Hal ini menunjukkan bahwa penambahan kompleksitas model tidak otomatis meningkatkan akurasi. Dengan jumlah data latih yang terbatas, model yang lebih kompleks berpotensi lebih sulit dilatih atau kurang mampu melakukan generalisasi.

Pengaruh laju pembelajaran juga bergantung pada arsitektur. Pada learning rate 0.01, LSTM dan GRU menghasilkan rata-rata test MAE yang lebih rendah daripada konfigurasi acuan dengan learning rate 0.001. Sebaliknya, ANN menghasilkan MAE yang lebih tinggi pada learning rate 0.01 dibandingkan konfigurasi acuannya. Perbedaan ini menunjukkan bahwa laju pembelajaran yang sesuai untuk satu arsitektur belum tentu sesuai untuk arsitektur lainnya. Namun, hasil test saja tidak digunakan untuk memilih konfigurasi terbaik; pemilihan tetap harus didasarkan pada MAE validasi.

Kelompok fitur masukan juga memengaruhi hasil prediksi. Pada RNN, penggunaan fitur trafik *net*, *call*, dan *sms* menghasilkan test MAE sebesar 227.6 ± 2.2, sedikit lebih rendah daripada 229.6 ± 5.1 ketika seluruh tujuh fitur digunakan. Pada GRU, kelompok fitur *net+waktu* menghasilkan MAE 239.7 ± 25.4, sedangkan penggunaan seluruh fitur menghasilkan 237.2 ± 9.3. Hasil tersebut menunjukkan bahwa penambahan fitur tidak selalu memperbaiki prediksi. Manfaat fitur tambahan bergantung pada seberapa relevan informasi tersebut terhadap pola trafik yang dipelajari model.

Pada eksperimen ukuran batch, tidak terdapat satu nilai yang terbaik untuk semua model. Batch 256 menghasilkan MAE ANN terendah, sedangkan batch 16 menghasilkan MAE terendah pada LSTM dan GRU. Pada RNN, rata-rata MAE batch 16 dan 256 sama-sama sebesar 228.3, tetapi simpangan baku batch 16 lebih rendah. Sementara itu, penggunaan loss MAE menghasilkan test MAE terendah pada keempat arsitektur dibandingkan loss MSE dan Huber. Hasil ini konsisten dengan tujuan evaluasi menggunakan MAE, meskipun tidak cukup untuk menyimpulkan bahwa loss MAE juga menghasilkan RMSE terbaik.

Secara keseluruhan, hasil ablasi memperlihatkan bahwa panjang jendela, jumlah lapisan, laju pembelajaran, kelompok fitur, ukuran batch, dan fungsi loss dapat memengaruhi kinerja model. Namun, besarnya pengaruh setiap faktor berbeda menurut arsitektur. Berdasarkan hasil yang tersedia, belum dapat ditentukan secara pasti satu hiperparameter yang paling berpengaruh untuk seluruh model karena faktor yang diuji memiliki rentang dan konfigurasi percobaan yang berbeda.

B. Perbandingan Antararsitektur dan Variasi Seed

Pada konfigurasi acuan di Duomo, RNN memperoleh test MAE terendah, yaitu 229.6 ± 5.1, diikuti GRU dengan 237.2 ± 9.3, LSTM dengan 273.6 ± 25.4, dan ANN dengan 309.9 ± 5.9. Hasil ini menunjukkan bahwa pada konfigurasi acuan, model rekuren RNN dan GRU memberikan prediksi yang lebih akurat daripada ANN berdasarkan MAE. Akan tetapi, hasil tersebut tidak berarti bahwa RNN selalu lebih unggul pada setiap konfigurasi, sebagaimana terlihat pada eksperimen ablasi.

Simpangan baku antar-seed juga perlu diperhatikan dalam menafsirkan perbedaan hasil. Pada konfigurasi acuan, simpangan baku ANN relatif kecil, yaitu 5.9, sedangkan LSTM memiliki simpangan baku 25.4. Pada ablasi ukuran jendela, RNN dengan jendela 48 jam menghasilkan 224.5 ± 11.7, sehingga variasi antar-seed tetap perlu dipertimbangkan ketika membandingkannya dengan konfigurasi lain yang selisih rata-ratanya kecil. Dengan demikian, perbedaan rata-rata MAE tidak selalu menunjukkan perbedaan kinerja yang konsisten pada setiap seed.

Perbandingan ini belum membuktikan secara statistik apakah perbedaan antararsitektur lebih besar daripada variasi antar-seed. Pengujian menggunakan tiga seed memberikan gambaran awal tentang variasi hasil, tetapi jumlah tersebut masih terbatas. Oleh karena itu, simpangan baku digunakan sebagai indikator variasi eksperimen, bukan sebagai bukti signifikansi statistik.

C. Generalisasi dan Periode Natal

Kinerja model juga perlu dinilai pada periode yang berbeda dari data latih. Pada konfigurasi acuan di Duomo, seluruh arsitektur menghasilkan MAE lebih tinggi pada periode Natal dibandingkan minggu test. Sebagai contoh, MAE RNN meningkat dari 229.6 ± 5.1 pada minggu test menjadi 421.2 ± 2.4 pada periode Natal. Pola ini menunjukkan bahwa hasil prediksi dapat memburuk ketika karakteristik trafik berubah dibandingkan periode yang digunakan untuk pelatihan.

Perubahan kinerja pada periode Natal dapat berkaitan dengan perubahan pola aktivitas pengguna selama periode liburan. Namun, eksperimen ini tidak secara langsung menguji penyebab perubahan trafik tersebut, sehingga hubungan itu perlu dipandang sebagai interpretasi yang masuk akal, bukan kesimpulan kausal.

Uji pada Stadio San Siro juga penting karena model yang berkinerja baik di Duomo belum tentu mempertahankan urutan kinerja yang sama di lokasi lain. Perbedaan karakteristik lokasi, seperti pola aktivitas dan tingkat trafik, dapat memengaruhi kesesuaian model terhadap data. Karena itu, hasil generalisasi

perlu dibandingkan berdasarkan perubahan MAE acuan dan konfigurasi terbaik pada masing-masing lokasi, bukan hanya berdasarkan nilai MAE absolut antar-lokasi.

D. Keterbatasan Studi

Studi ini memiliki beberapa keterbatasan. Pertama, data berasal dari wilayah Milan sehingga hasilnya belum tentu berlaku untuk kota atau jaringan lain dengan karakteristik pengguna berbeda. Kedua, periode pelatihan relatif singkat, yaitu sekitar empat minggu, sehingga model memiliki keterbatasan dalam mempelajari variasi musiman atau pola trafik jangka panjang. Ketiga, evaluasi menggunakan satu pembagian waktu kronologis. Hasilnya dapat berubah apabila periode pelatihan, validasi, dan pengujian dipindahkan.

Selain itu, setiap konfigurasi dijalankan menggunakan tiga seed. Jumlah ini memberikan gambaran awal tentang variasi hasil, tetapi belum cukup untuk menggambarkan seluruh ketidakpastian proses pelatihan secara menyeluruh. Ablasi juga mengubah satu faktor pada satu waktu, sehingga interaksi ant hiperparameter belum diuji secara sistematis. Sebagai contoh, ukuran batch yang baik pada satu laju pembelajaran belum tentu memberikan hasil yang sama pada laju pembelajaran lainnya.

Dengan keterbatasan tersebut, hasil penelitian ini lebih tepat digunakan untuk membandingkan perilaku ANN, RNN, LSTM, dan GRU pada konfigurasi serta periode yang diuji, bukan untuk menetapkan satu arsitektur sebagai model terbaik secara universal. Penelitian lanjutan dapat menggunakan lebih banyak seed, beberapa pembagian waktu, periode data yang lebih panjang, dan pengujian pada lebih banyak lokasi untuk memperoleh kesimpulan yang lebih kuat.

IV. Kesimpulan

Hasil eksperimen menunjukkan bahwa RNN memperoleh MAE terendah pada konfigurasi acuan, yaitu 229.6 ± 5.1 pada data uji Duomo, dibandingkan ANN, LSTM, dan GRU. Pada ablasi fungsi loss, penggunaan MAE menghasilkan nilai MAE uji terendah untuk RNN, yaitu 207.6 ± 2.8, dibandingkan 229.6 ± 5.1 dengan MSE dan 225.3 ± 3.0 dengan Huber. Hasil ablasi menunjukkan bahwa pilihan hiperparameter dapat memengaruhi kinerja model, tetapi konfigurasi terbaik dapat berbeda antararsitektur. Kesimpulan ini masih terbatas pada periode dan lokasi yang diuji, sehingga diperlukan pengujian pada lebih banyak lokasi dan rentang waktu untuk menilai kemampuan generalisasi secara lebih luas.

Kontribusi Anggota

Grasia Okta Adelia	Pengerjaan ablasi A1–A5; penulisan abstrak, pendahuluan, serta bagian Data dan Metode hingga Konfigurasi Terbaik.
Egista Marga Kola	Pengerjaan ablasi Bagian B; penyusunan README; penulisan bagian Uji Generalisasi hingga Perbandingan Antararsitektur dan Variasi Seed.
Muhammad Allam Dzaky	Pengerjaan Bagian C hingga penutup; penulisan bagian Generalisasi dan Periode Natal hingga Daftar Pustaka.

Pernyataan Penggunaan AI

Dalam penyusunan laporan ini, ChatGPT digunakan untuk membantu merapikan bahasa dan tata penulisan laporan, menganalisis kesalahan dalam kode, serta membantu menemukan dan memperbaiki kesalahan kode (*debugging*). Seluruh angka dan hasil eksperimen yang disajikan dalam laporan diperoleh dari proses eksperimen yang dijalankan oleh kelompok.

Kode dan Data

Kode program, notebook beserta output, dan seluruh hasil eksperimen tersedia di repositori GitHub berikut: https://github.com/grasiaoktaa/dlw-tugas-ra-124400059

Pustaka

[1] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual attention-based federated learning for wireless traffic prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10.

[2] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[3] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder–decoder for statistical machine translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734.

[4] G. Barlacchi, M. De Nadai, R. Larcher, A. Casella, C. Chitic, G. Torrisi, F. Antonelli, A. Vespignani, A. Pentland, and B. Lepri, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015.